

Задача 1. Эффективный NN Task

- 1) S - сторона изображения, $res = S \times S$
- 2) Precision - FP32, 1 el. 4 byte
- 3) Flops = 2 MAC
- 4) Числам слоев conv и linear, ReLU, MaxPool, AvgPool - ~~числа~~
- 5) считать время $\frac{M}{S^2}$ - число элементов слоя на канал и S^2

I. Размер слоя по ширине

$$H_{out} = \lfloor (H_{in} + 2p - k) / S \rfloor + 1, p = k // 2$$

Слой	Вход (C x H x W)	M / S^2
Conv 7x7 32x32	$32 \cdot S/2 \cdot S/2$	$32/4 = 8$
Max pool 3x3 32	$32 \cdot S/4 \cdot S/4$	$32/16 = 2$
Conv 5x5 32 → 64	$64 \cdot S/4 \cdot S/4$	4
Conv 3x3 52 → 128	$128 \cdot S/8 \cdot S/8$	2
Conv 2x1 128 → 256	$256 \cdot S/8 \cdot S/8$	4
Conv 3x3 52 → 256	$256 \cdot S/16 \cdot S/16$	1
Conv 2x1 256 → 512	$512 \cdot S/16 \cdot S/16$	2
Avg → Flatten	512	не считается
Linear 512 → 256	256	—
Linear 256 → 100	100	—

II. Беса

$$\text{conv без bias: } \text{Count} = C_{in} \cdot k^2$$

conv1	32 · 3 · 49	4704
conv2	64 · 32 · 25	51200
conv3	128 · 64 · 9	73728
conv4	256 · 128 · 1	32768
conv5	256 · 256 · 9	589824
conv6	512 · 256 · 1	131072
fc1	512 · 256	131072
fc2	256 · 100	25600
Woro		1039968

$$W = 4 \cdot 1039968 = 4159872 \approx 4.16 \text{ MB}$$

Біас y gbyk Linear =
356 нрл 2,4 КБ $\Rightarrow$
мормо нрмне фрм

IV FLOPs

$$MAC_{conv} = C_{out} \cdot H_{out}^2 \cdot C_{in} \cdot k^2$$

conv	$C_{out} \cdot H_{out}^2 (BS^2)$	$\times C_{in} \cdot k^2$	MAC/S ²
conv1	8	$\cdot 3 \cdot 49 = 147$	1176
conv2	4	$\cdot 32 \cdot 25 = 800$	3200
conv3	2	$\cdot 64 \cdot 9 = 576$	1152
conv4	4	$\cdot 128$	512
conv5	1	$\cdot 256 \cdot 9 = 2304$	2304
conv6	2	$\cdot 256$	512
Woro			8856

$$\text{Head: } 512 \cdot 256 + 256 \cdot 100 = 156672 \text{ MAC}$$

$$FLOPs(S, B) = B \cdot 2 \text{ MAC}(S) = 2B(8856S^2 + 156672)$$

$$FLOPs(S, B) = 17712BS^2 + 313344B$$

II Bytes moved (S, B)

$$\text{Bytes}(S, B) = \text{Bytes weights} + \text{Bytes activations}(S, B)$$

Bytes weights - уже посчитано $\approx 4\,159\,872 \approx 4.16 \text{ MB} = W$

$$\text{Bytes}(S, B) = W + 4 \cdot B \sum_L (N_{in}^L + N_{out}^L)$$

layer	$\text{bytes}(N_{in}/S^2)$	$\text{bytes}(N_{out}/S^2)$	sum
conv1	3	8	11
MaxPool	8	2	10
conv2	2	4	6
conv3	4	2	6
conv4	2	4	6
conv5	4	1	5
conv6	1	2	3
AvgPool	2	≈ 0	2
итого			49

49 - эл.

Б данных $\approx$

$$4 \cdot 49 \cdot B \cdot S^2 =$$

$$= 196 B S^2$$

Аhead забирать данные из OGB = 1636 эл = 6544 байт на слой.

$$\text{Bytes}(S, B) = 196 B S^2 + 6544 B + 4\,159\,872$$

Допущение: ReLU не учитываем, но на самом деле имеет $\approx$ индекс тензоров. Но пропорцию займает 12-15% GPU времени при данных S, B.

I Memory (S, B)

$$\text{Memory}(S, B) = W + W_{cache} + \max \text{Mact}(S, B)$$

W - вес сети,

W_{cache} - вес градиентов on BLO S, $\approx 9.57 \text{ MB}$

max Macf (S, B) - максимальное общее количество кубических операций через все уровни уменьшения

$$\text{Macf}(S, B) = 4 \cdot B \cdot (\text{in} S^2 + \text{out} S^2)$$

Момент	число операций	число ops/S^2
conv1	$\text{in}(3) + \text{out}(8)$	11
Maxpool	$\text{in}(3) + \text{out}(8) + \text{pool}(\text{out}(2)) + \text{index}(4)$	13
conv2	$\text{in}(3) + \text{pool}(\text{in}(2)) + \text{out}(4)$	9
conv3	$\text{in}(3) + 4 + \text{out}(3(2))$	9
conv4	$\text{in}(3) + \text{out}(3(2)) + \text{out}(4(4))$	9
conv5	$\text{in}(3) + \text{out}(4(4)) + \text{out}(5(1))$	8
conv6	$\text{in}(3) + \text{out}(5(1)) + \text{out}(6(2))$	6
head	$\approx \text{in}(3)$	3

Далее: переходим на Maxpool

$$\begin{aligned} \text{Memory}(B, S) &= W + W_{\text{cache}} + 4 \cdot 13 B S^2 = \\ &= 4,16 + 9,53 + 68 B S^2 \approx 13,73 + 68 B S^2 \end{aligned}$$

IV Latency (S, B, Θ)

$$\text{Latency}(S, B, \Theta) = \max \left(\Theta_2, \frac{\text{Bytes}(S, B)}{\Theta_0}, \frac{\text{FLOPs}(S, B)}{\Theta_1} \right)$$

Θ_0 - операционная пропускная способность памяти, байт/с

Θ_1 - операционная пропускная способность, FLOPs/с

Θ_2 - минимальное время одного запуска: запуск CUDA ядра + python overhead + запуск WSL2

VII Energy

$$Energy = P_{idle} \cdot Latency(S, B, Q) + e_{mem} B \cdot k(S, B) + e_c \cdot FLOPS(S, B)$$

P_{idle} — мощность "высвобождаемая" аппаратом и его непосредственно

e_{mem} — энергия на чтение/запись в память

e_c — энергия на один FLOP

$$P_{idle} = 51,4 \text{ W}$$

$$e_{mem} = 2.12 \cdot 10^{-8} \frac{\text{J}}{\text{байт}}$$

$$e_c = 9.2 \cdot 10^{-22} \frac{\text{J}}{\text{FLOP}}$$